Predicción de la puntuación de reseñas de productos

Reseñas en español, de 1 a 5 estrellas

Materia: Tópicos Avanzados

Docente: Kenji Kawaida

Integrantes:

- De los Ríos Alejandro
- Flores Eudenia
- Gonzales José Brayan
- Murillo Diana

El problema

Dado el texto de una reseña, estimar cuántas estrellas (1 a 5) le puso quien la escribió.

- Clasificación supervisada con 5 clases.
- Reseñas de productos de Amazon, en español.
- La web muestra el resultado y el pre procesamiento paso a paso.

ENTRADA

“Nunca me respondieron por mi reclamo, el producto no encendía y estaba roto.”

▼

SALIDA



Estrellas y probabilidad de cada puntaje

Arquitectura

1

Datos

Python, pandas, scikit-learn

2

NLP

NLTK (stemming), spaCy (stop words)

3

Modelo

TF-IDF + regresión logística, joblib

4

Backend

FastAPI, pydantic, pytest

5

Frontend

React, TypeScript, Vite, Bootstrap

Reseña escrita en la web → **API: /predict y /preprocess** → **Pipeline guardado (NLP + modelo)** → **Estrellas y probabilidades**

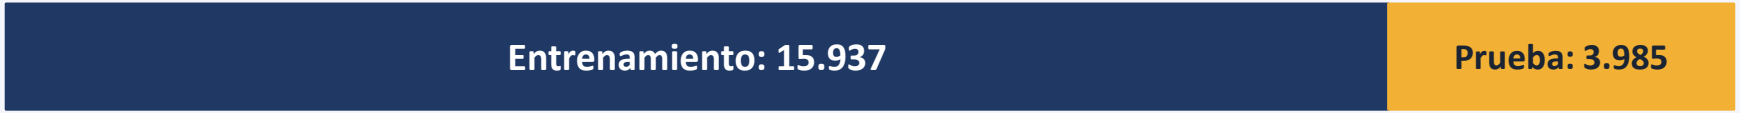
Dataset

200.000
reseñas en la fuente

20.000
muestra: 4.000 por puntaje

19.922
después de limpiar

División 80 % / 20 %, estratificada por puntaje, semilla 42



MARC (Multilingual Amazon Reviews Corpus), copia SetFit/amazon_reviews_multi_es en Hugging Face. Descargado el 28/10/2026. Licencia: la copia no indica; el corpus original permite solo investigación académica (este proyecto lo es).

Análisis exploratorio



0 valores faltantes y puntajes fuera de 1 a 5

4.000 reseñas de cada puntaje (clases parejas)

28 palabras en promedio; mediana 22, máximo 458

«no», «sin» y «ni» aparecen arriba porque las negaciones no se eliminan.

Pipeline de NLP

Normalización → Tokenización → Stop words → Stemming → N-gramas → TF-IDF → Regresión logística

ANTES

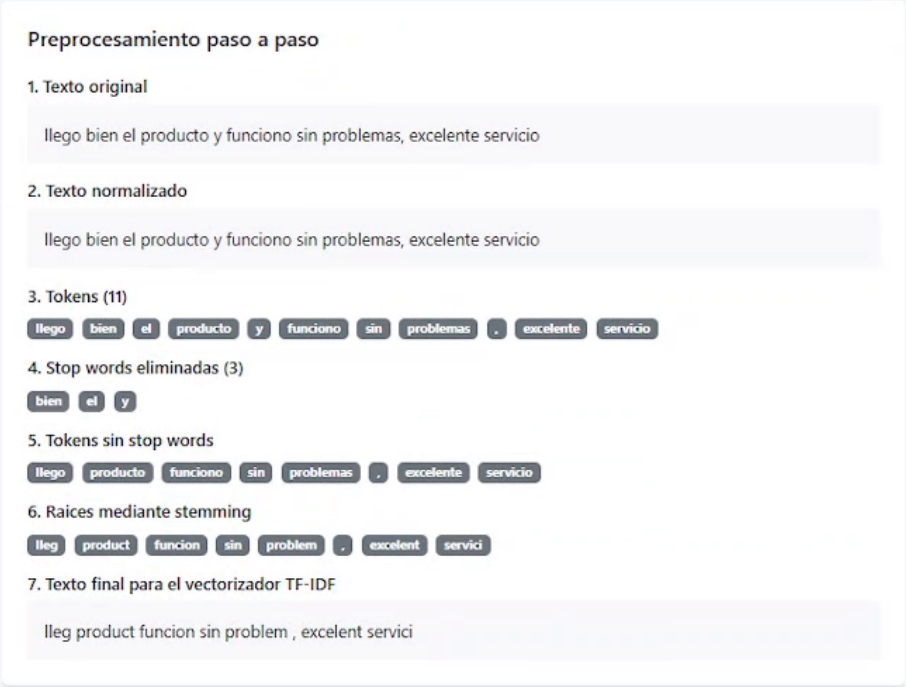
llego bien el producto y funciono sin problemas, excelente servicio

DESPUÉS (lo que recibe el vectorizador)

lleg product funcion sin problem , excelent servici

- Se conservan las negaciones (no, sin, ni…): «funciona» y «no funciona» dicen cosas opuestas.
- Lematización (spaCy) se probó y se descartó: con stemming el F1 fue mayor.

Pre procesamiento en el sitio web



La API devuelve cada etapa y el frontend la muestra:

- texto original y normalizado
- tokens
- stop words eliminadas
- raíces (stemming)
- texto final para TF-IDF

Modelo y línea base

LÍNEA BASE

Siempre predice la clase más frecuente

Accuracy	20,05 %
F1 macro	6,68 %
Error medio	1,40 est.

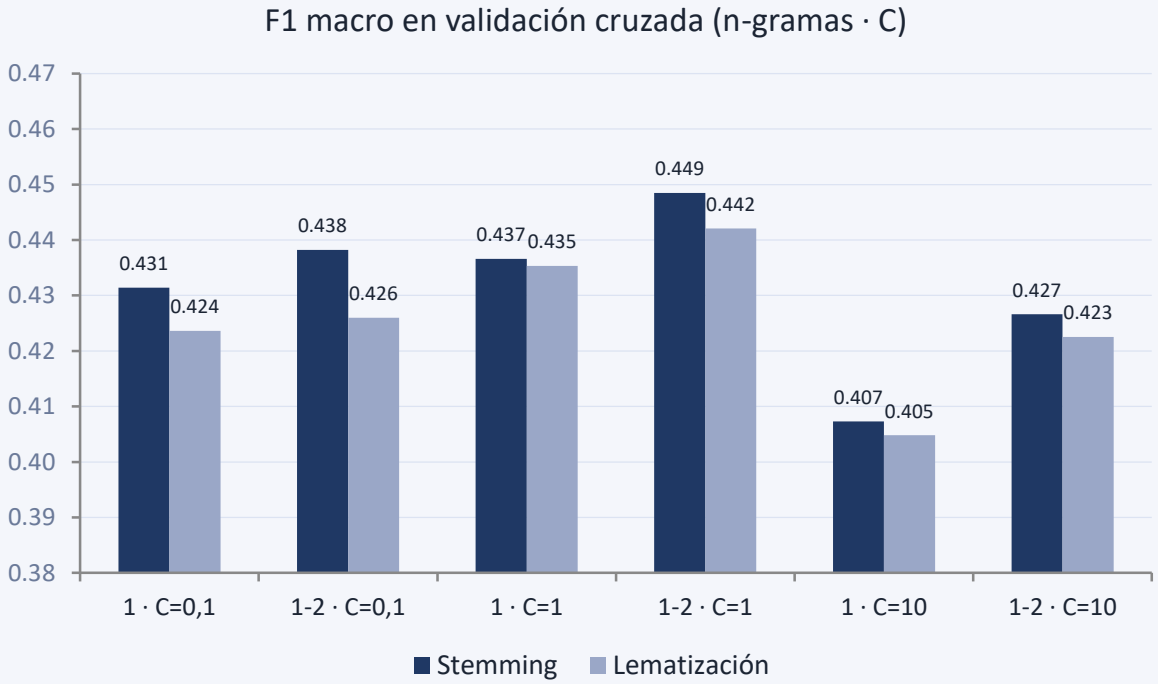
REGRESIÓN LOGÍSTICA + TF-IDF

Entrega la probabilidad de cada puntaje

Accuracy	45,19 %
F1 macro	44,79 %
Error medio	0,75 est.

Resultados sobre las 3.985 reseñas de prueba. Configuración elegida: stemming, unigramas + bigramas, C = 1.

Comparación de configuraciones



12 configuraciones, validación cruzada de 3 particiones.

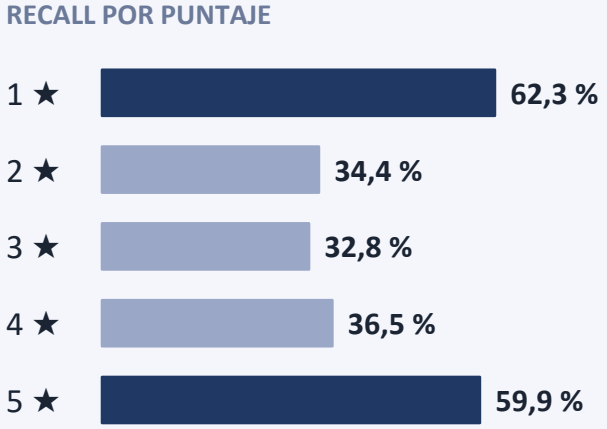
- Stemming supera a lematización en las seis comparaciones.
- Con bigramas el F1 sube (stemming, C=1: 0,437 a 0,449).
- C = 1 rinde mejor que 0,1 y que 10.

Elegida: stemming, 1-2, C = 1 (F1 = 0,4485).

Resultados por puntaje

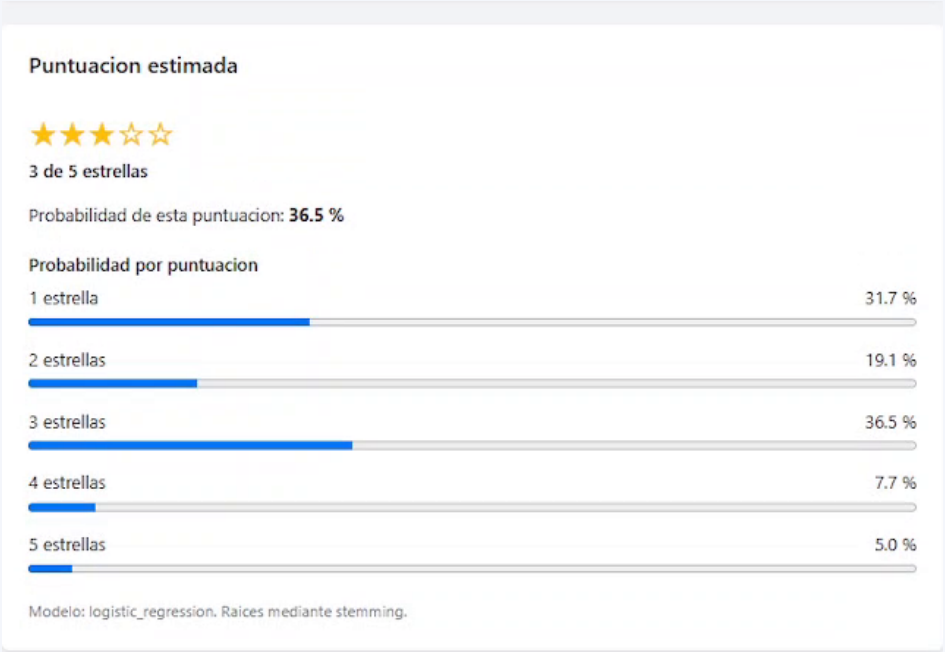
Real \ Pred.	1	2	3	4	5
1	**498**	192	75	20	14
2	232	**275**	209	49	34
3	109	198	**262**	138	91
4	28	72	152	**290**	252
5	14	42	68	195	**476**

Matriz de confusión (filas: puntaje real, columnas: predicho)



72 % de los 2.184 errores se equivocan por una sola estrella

Demostración



Endpoints de la API

GET	/api/v1/health
POST	/api/v1/predict
POST	/api/v1/preprocess
GET	/api/v1/models/info
GET	/api/v1/models/metrics
GET	/api/v1/models/experiments

El texto debe tener entre 3 y 5.000 caracteres; si no, la API responde con un error claro.

Limitaciones

Puntajes intermedios

Las reseñas de 2, 3 y 4 estrellas se reconocen peor (recall de 33 % a 37 %). Las de 3 estrellas pueden ser ambiguas.

Vocabulario parecido

Reseñas de puntajes distintos usan palabras similares, y el modelo cuenta palabras.

Datos balanceados

4.000 por puntaje: no necesariamente representa la distribución real de una tienda.

Una sola fuente

Todo viene de Amazon. product_id y category de la versión simulada son inventadas y no sirven para análisis.

Uso de asistentes de IA

- Datos e informe: Claude (Anthropic), para elegir el dataset, escribir y probar los scripts de descarga, revisión y división, y redactar el informe.
- Pruebas y modificaciones de NLP y ML: Codex.
- Cada integrante puede explicar y modificar lo que subió.

¿Preguntas?